

INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO



Regresión del consumo energético en México

PRESENTAN:

Cabello Cárdenas Ulises Abdiel

Gutiérrez Martínez Diana Judith

Herrera Moreno Sayuri

Martínez Salinas Emiliano

Verde Soria Aline Pamela

Onofre Rosales Rodrigo

Ciudad de México, a 24 de marzo 2026

ÍNDICE GENERAL

<i>Resumen ejecutivo</i>	<i>2</i>
<i>Planteamiento del problema</i>	<i>3</i>
<i>Objetivos.....</i>	<i>3</i>
<i>Objetivos específicos</i>	<i>3</i>
<i>Descripción de datos</i>	<i>4</i>
<i>Metodología</i>	<i>4</i>
<i>Resultados.....</i>	<i>5</i>
<i>Conclusiones.....</i>	<i>7</i>

Resumen ejecutivo

El presente proyecto tiene como objetivo implementar un modelo de regresión no lineal para pronosticar la demanda energética en el área OCC y del sistema SIN, utilizando información histórica de generación y demanda de energía. Para iniciar con el proyecto realizamos un análisis exploratorio del dataset para entender las variables con las que estamos trabajando, identificar la variable objetivo, analizar cómo se comporta a lo largo del tiempo e identificar las variables más significativas.

Una vez preparados los datos, aplicamos ingeniería de características donde generamos variables de tiempo y rezagos de demanda para añadir más información. Con base en esto, se implementaron distintos modelos de regresión no lineal para identificar el más adecuado para el pronóstico de la demanda energética.

Planteamiento del problema

La demanda energética es una variable de gran importancia para el análisis y desarrollo del proyecto, ya que, con esta, podemos comprender patrones de consumo y a la toma de decisiones. En este proyecto, buscamos modelar la variable de estimación de demanda por balance, la cual es una medida continua y mide la demanda energética.

Ya que la demanda varía a lo largo del tiempo, es necesario ocupar un modelo que pueda capturar su comportamiento y pronosticar mediciones. Con este contexto, el problema principal del proyecto consiste en construir un modelo de regresión no lineal que permita pronosticar la demanda energética.

Objetivos

Pronosticar la demanda energética en el área OCC del Sistema Interconectado Nacional (SIN), a partir de datos históricos del CENACE del período 2020–2024, evaluando diferentes modelos de predicción para determinar cuál ofrece el mejor desempeño.

Objetivos específicos

1. Recopilar la información de demanda energética de CENACE.
2. Realizar un análisis exploratorio para entender con qué variables estamos trabajando, y para identificar la variable objetivo, así como valores atípicos, su significado y una descripción más específica de las columnas.
3. Limpiar los datos para el modelado, y por medio de ingeniería de características, crear nuevas columnas.
4. Implementar distintos modelos de regresión no lineal para pronosticar la demanda energética.
5. Evaluar y comparar los modelos implementados por medio de métricas como MAE, RMSE y R^2 .
6. Seleccionar el modelo que tenga mejor desempeño para pronosticar la demanda del área OCC.

Descripción de datos

Utilizamos un dataset que registra datos durante el tiempo. El dataset contiene información de diferentes sistemas y áreas, así como variables de demanda como:

- Generación (MWh): Energía generada en el periodo
- Importación total (MWh): Energía recibida
- Exportación total: Energía enviada
- Estimación de demanda por balance (MWh): Variable objetivo, demanda energética a pronosticar
- Timestamp: Fecha y hora de cada registro
- Sistema: Sistema al que pertenece el registro
- Área: Área específica dentro del sistema

Después del análisis exploratorio base, identificamos que el sistema SIN tenía la mayor cantidad de información, por lo que nos enfocamos en dicho sistema. De igual forma, observamos que las áreas tenían comportamientos distintos, por lo que seleccionamos el área OCC como filtrado final para empezar la etapa de modelado.

Metodología

La primera etapa del desarrollo del proyecto fue realizar un análisis exploratorio de datos para comprender la estructura de los datos con los que estábamos trabajando, identificar la variable objetivo e identificar patrones en el comportamiento de la demanda a lo largo del tiempo. En esta etapa analizamos los sistemas y áreas que estaban en la base de datos, identificando que el sistema SIN tenía la mayoría de información, además que las áreas tenían comportamientos diferentes, por lo que lo delimitamos al área OCC.

Una vez seleccionado nuestro dataset final, preparamos la información, identificando que no teníamos ningún valor vacío en ninguna columna. Aplicamos ingeniería de características agregando nuevas variables de rezagos de una hora, 24 horas y 168 horas para que el modelo tuviera más información del comportamiento. Además, realizamos un análisis de correlación de la demanda con distintos rezagos para identificar las variables más relevantes de estas variables.

Con los datos preparados, definimos la variable objetivo, estimación de demanda por balance (MWh). Después, dividimos el dataset en entrenamiento y prueba para evaluar el desempeño de distintos modelos de regresión no lineal. Finalmente, los modelos implementados se compararon con métricas como MAE, RMSE y R^2 con el objetivo de identificar cuál tenía el mejor desempeño para pronosticar la demanda energética en el área OCC del sistema SIN.

Resultados

Una vez realizada la preparación de los datos y la construcción de variables rezagadas, se implementaron dos modelos de regresión para estimar la demanda energética en el área OCC, estos fueron regresión polinomial de grado 2 y XGBoost.

Para evaluar su desempeño se utilizaron las métricas MAE, RMSE y R^2 . Los resultados obtenidos fueron los siguientes:


Métrica	XGBoost	Regresión polinomial grado 2
MAE	75.67	115.81
RMSE	113.22	157.95
R^2	0.9903	0.9811

A partir de estas métricas, se observa que XGBoost presentó el mejor desempeño general, ya que obtuvo los valores más bajos de error y un valor de R más cercano a 1. Esto indica que sus predicciones se ajustaron mejor a los valores reales de la demanda.

Por su parte, la regresión polinomial de grado 2 también mostró resultados favorables, y mejoró respecto a una regresión lineal simple, ya que incorpora curvatura e interacciones entre las variables de entrada. Sin embargo, sus errores fueron mayores que los de XGBoost, por lo que su capacidad predictiva fue menor.


Además de las métricas, se revisaron las gráficas de residuos para analizar el comportamiento de ambos modelos.

Figura1. Residuales e importancia de features para el modelo XGBoost



En la Figura 1 se puede observar que los residuos obtenidos de la aplicación de XGBoost oscilan, aproximadamente, entre -350 MWh y 280 MWh durante el primer mes analizado. Además, su distribución está mayormente concentrada alrededor de cero, lo que indica que, en general, el modelo presenta errores menores y un comportamiento más estable. Sin embargo, al revisar el error promedio por hora del día se observan variaciones importantes en ciertos horarios, por ejemplo, a las 16 hrs, por lo que no puede afirmarse que los errores sean completamente aleatorios.

Figura 2. Residuales de regresión polinomial grado 2



La figura anterior muestra que para el caso de la regresión polinomial de grado 2 los residuos oscilan aproximadamente entre -420 MWh y 470 MWh, es decir, presentan una dispersión mayor que los de la figura 1. Además, al analizar el error promedio por hora del día es notable que hay horas en las que el modelo calcula una demanda más alta que la real y otras en las que el cálculo es menor que la demanda. En este sentido, se puede observar que la regresión polinomial no representa completamente el comportamiento de los datos.

En general, XGBoost representa de mejor manera el comportamiento de los datos reales en comparación con la regresión polinomial de grado 2. Las métricas de desempeño observadas muestran un menor MAE y RMSE, además de un valor de R^2 más cercano a 1. Asimismo, en este modelo los residuos se encuentran más concentrados alrededor de cero y con menor dispersión que en la regresión polinomial, lo que refleja un ajuste más preciso.

Conclusiones

A partir de los resultados obtenidos, se observó que, aunque XGBoost presentó un mejor desempeño que la regresión polinomial de grado 2, el fenómeno analizado no se adapta por completo a este tipo de modelos generales de regresión. Esto se puede observar especialmente en el comportamiento de los residuos, ya que en ambos casos siguieron apareciendo patrones de error en ciertos momentos.

Así, se puede concluir que la demanda energética presenta una dinámica temporal más compleja de lo que estos modelos alcanzan a representar por completo. A pesar de ello, al comparar XGBoost con el pronóstico original incluido en la base de datos, se observó que el modelo obtuvo errores considerablemente menores, lo que indica un mejor ajuste para el conjunto analizado.

En este sentido, se sugiere que en trabajos futuros se exploren modelos más enfocados en el análisis de series de tiempo, ya que este tipo de enfoques podría representar de mejor manera el fenómeno de la demanda energética. Además, se considera conveniente realizar más pruebas para evaluar el comportamiento del modelo en otros periodos y bajo otras condiciones.

REFERENCIAS

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An introduction to statistical learning: With applications in R (2nd ed.). Springer.

Montgomery, D. C., Peck, E. A., & Vining, G. G. (2012). Introduction to linear regression analysis (5th ed.). Wiley.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining (pp. 785–794). ACM.